

# MÉTHODES D'OPTIMISATION STOCHASTIQUES

---

Xavier Olive

avec l'aide de Nathalie Bartoli, Gaspard Berthelin, Alexandre Gondran,  
Olivier Poitou et Rémy Priem

- ▶ appréhender les situations dans lesquelles les méthodes stochastiques (*métaheuristiques*) sont pertinentes ;
- ▶ comprendre les grandes familles d'algorithmes d'optimisation stochastique ;
- ▶ manipuler (parfois coder) trois algorithmes parmi les plus utilisés et les essayer sur des problèmes « jouets ».

**Évaluation** Chaque binôme devra étudier une méthode d'optimisation non couverte par le cours et la présenter devant le groupe lors de la dernière séance (le 3 décembre).

- ▶ 7 novembre :  
Recuit simulé – *Simulated annealing*
- ▶ 12 novembre :  
Algorithmes génétiques – *Genetic algorithms*
- ▶ 20 novembre :  
CMA-ES
- ▶ 3 décembre *Présentations*



- ▶ Ant colony optimisation
- ▶ Artificial bee colony
- ▶ Genetic algorithms (advanced version)
- ▶ Harmony search
- ▶ Particle swarm optimisation
- ▶ Shuffled frog leaping
- ▶ Stochastic (constraint based) local search
- ▶ Tabu search
- ▶ Cross-entropy method ?

- ▶ Ant colony optimisation
- ▶ Artificial bee colony
- ▶ Genetic algorithms (advanced version)
- ▶ Harmony search
- ▶ Particle swarm optimisation
- ▶ Shuffled frog leaping
- ▶ Stochastic (constraint based) local search
- ▶ Tabu search
- ▶ Cross-entropy method ?

**Consigne :** Présenter chaque méthode de manière intuitive.  
Une démonstration sur un problème jouet sera valorisée  
(codée par vos soins *ou* récupérée sur le net)

# INTRODUCTION

---

$$\min_x f(x)$$

Notations :

- ▶  $x$  est un vecteur de *variables*, ou d'inconnues;
- ▶  $f$  est une *fonction objectif*, ou fonction d'évaluation.

La *modélisation* d'un problème consiste à identifier des variables et une fonction objectif.



$$\min_x f(x) \text{ en respectant } c(x)$$

Notations :

- $c$  est une fonction *contrainte*, à valeurs dans  $\{\top, \perp\}$ .

Dans le cas d'une optimisation non contrainte, on a

$$\forall x : c(x)$$

Les variables  $x$  peuvent être à valeurs dans :

- ▶ un ensemble *continu*, comme  $\mathbb{R}$ ;
- ▶ un ensemble *discret*, comme  $\mathbb{Z}$ ;
- ▶ un ensemble *fini*, comme  $\{0, 1\}$ .

Les variables d'un problème peuvent prendre leurs valeurs sur des ensembles de nature différente.

- ▶ Les méthodes de résolution adaptées à certains problèmes garantissent de trouver le minimum global s'il existe.
- ▶ Pour d'autres types de problèmes, il est difficile de savoir qu'on a trouvé un minimum global : les algorithmes convergent vers des minima locaux.

- ▶ Les méthodes de résolution peuvent toujours converger de la même manière : on parle de **méthode déterministe**.
- ▶ Si deux exécutions du programme convergent différemment, on parle alors de **méthode stochastique**.  
*Attention à la graine de votre programme !*

- ▶ Programmation non linéaire  
(gradient, gradient conjugué, BGFS, etc.);
- ▶ Programmation linéaire  
(simplexe; Dantzig, 1947);
- ▶ Programmation linéaire en nombres entiers (MILP);
- ▶ Programmation par contraintes (CSP)

- ▶ Programmation non linéaire  
(gradient, gradient conjugué, BGFS, etc.);
  - ▶ Programmation linéaire  
(simplexe; Dantzig, 1947);
  - ▶ Programmation linéaire en nombres entiers (MILP);
  - ▶ Programmation par contraintes (CSP)
- 
- ▶ Pour MILP et CSP, la taille du problème et/ou des domaines peut être un facteur fortement limitant.

C'est la solution de secours quand les méthodes classiques sont inefficaces : on obtient une solution de bonne qualité en un temps raisonnable.

- ▶ On cherche *au hasard*  $x_{k+1}$  dans le voisinage de  $x_k$ , en combinant aspects d'**optimisation** et d'**exploration**.
- ▶ Métaphores de comportements observés dans la nature.
- ▶ Métaheuristique = **méthode stochastique générique** à adapter à chaque problème.

Ces méthodes sont efficaces quand :

- ▶ la fonction d'évaluation est de type boîte noire ;
- ▶ le problème se formalise bien en MILP/CSP mais le domaine est trop grand (cf. complexité) ;
- ▶ la fonction d'évaluation est bruitée (→ CMA-ES) ;



Deux grandes classes de méthodes :

- ▶ les **méthodes par trajectoire**: on manipule un élément à la fois dans l'espace des solutions pour tenter de construire une trajectoire qui converge vers un optimum.
  - recherche locale, recuit simulé, etc.
- ▶ les **méthodes par population**: on manipule plusieurs éléments à la fois ; les meilleurs éléments guident la génération de la population à l'itération suivante.
  - algorithmes génétiques, essais particuliers, etc.

## RECUIT SIMULÉ

---

### Méthode par trajectoire inspirée de la métallurgie

- ▶ On choisit au hasard une solution initiale à **énergie**  $E_0$  et une **température initiale** élevée  $T_0$ ;
- ▶ À chaque itération, on choisit un voisin de l'état précédent, qui correspond à une variation d'énergie  $\Delta E$ :
  - si  $\Delta E < 0$ , la modification est appliquée;
  - sinon, on l'accepte avec une probabilité  $e^{-\frac{\Delta E}{T}}$ .
- ▶ La température suit une loi décroissante.

L'algorithme étant facile, nous allons le coder tout en nous assurant d'avoir bien compris où se situe la vraie difficulté :

- ▶ le choix des paramètres;
- ▶ la définition d'un voisinage.

Nous allons le développer sur une fonction 2D générée aléatoirement, puis le tester sur un plus gros problème.

# ALGORITHMES GÉNÉTIQUES

---

## Méthode par population, l'évolution selon Darwin

- ▶ On choisit au hasard une population<sup>1</sup> initiale de taille fixée ;
- ▶ **Sélection**: à chaque itération, on choisit des éléments parmi les mieux évalués ;
- ▶ **Croisement**: à chaque itération, on hybride les éléments sélectionnés pour générer la génération suivante ;
- ▶ **Mutation**: à chaque itération, une partie de la population est légèrement modifiée pour la génération suivante ;

---

1. On parle ici de *chromosome*.

Aujourd'hui encore, nous allons coder cette méthode pour :

- ▶ essayer différentes stratégies de sélection, croisement et mutation sur un problème jouet;
- ▶ trouver des tailles de population, taux de croisement et de sélection efficaces pour notre problème.

```
initialize population
foreach iteration :
    evaluate population
    append the k best elements into your new population
    for a1, a2 in selection(population) :
        b1, b2 = cross(a1, a2)
        "sometimes" mutate b1 and/or b2
    append b1, b2 to your new population
```



- ▶ **Tournoi :**

Tirer deux éléments au hasard, garder le meilleur des deux.

- ▶ **Roulette russe :**

Tirer un élément au hasard (loi uniforme), avec une probabilité proportionnelle à l'évaluation de chaque élément.

- ▶ **Croisement en un point :**

On découpe les chromosomes en un point tiré au hasard.

- ▶ **Croisement en deux points :**

On découpe les chromosomes en deux points tirés au hasard.

- ▶ **Croisement uniforme :**

On tire au sort pour chaque gène si on échange ou pas.

## CMA-ES

---